

EDA: Home Credit Default Risk

Justicia e incertidumbre en concesión de crédito


Taller B4-T1 · Diseño de Redes Confiables

Diego Muñoz · Luis Coello · Jesús Bussion

Capa custom: conocimiento de dominio


```
ratio = AMT_CREDIT /  
AMT_INCOME_TOTAL
```

La red recibe explícitamente una variable con sentido financiero: cuánto crédito se pide frente a cuánto se gana.




El ratio usado en el código es `AMT_CREDIT / AMT_INCOME_TOTAL`, calibrado en train.

Calibrar la saturación




Elegimos $k = \text{p95} = 9,1453$: el 95% de train queda en zona útil y la cola extrema se comprime.

`tanh`: saturar sin apagar el aprendizaje



Forma general. La derivada (morado) nunca llega a 0.




Nuestra curva: `ratio = k` → $\tanh(1) \approx 0,76$.

Frente a `clip`, la `tanh` conserva gradiente en toda la cola: satura sin apagar el aprendizaje. Trabajamos solo en la rama positiva (`ratio ≥ 0`).

Fairness: el sesgo no es trivial



Distinta tasa de impago por género.



EXT_SOURCE_1 correlaciona **-0,31** con el género.

El género deja huella en otras variables (*proxies*): borrarlo no basta. Por eso penalizamos la dependencia de la **salida**, no la presencia de la variable.

Loss FAIR

$$\text{Loss} = \text{BCE}(y, \hat{y}) + \lambda \cdot \rho(\hat{y}, s)^2$$

Por qué Pearson

- Captura dependencia lineal.
- Es barata: coste lineal por batch.
- Es derivable con `keras.ops`.

Dos detalles clave

- Va al cuadrado: empuja a 0, no a -1.
- El género no entra como input; solo viaja en `y_true`.

Evaluadas y descartadas

CKA / HSIC · **Spearman** (soft-rank) — equivalentes o más costosas en nuestro caso.

λ : la palanca del compromiso

Y

AUC

Rendimiento predictivo. Queremos mantenerlo alto.

X

Dependencia FAIR

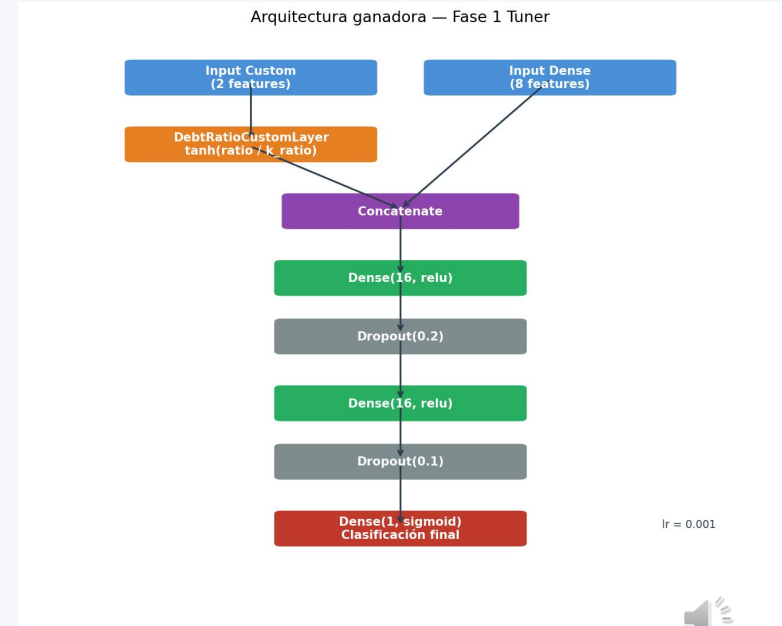
Correlación residual con la variable sensible. Queremos bajarla.

Cada valor de λ produce un punto distinto: precisión frente a justicia.

Arquitectura ganadora — Fase 1 Tuner


Hiperparámetro	Rango
num_layers	1, 2
units_i	16, 32, 48, 64
dropout_i	0.1, 0.2, 0.3, 0.4
lr	1e-3, 5e-4
lambda_fair	fijo a 0.0

Objetivo de validación: `val_auc`




Frontera de Pareto: AUC vs Equidad

Cada punto corresponde a un valor de λ . El trade-off precisión–equidad es claro: $\lambda = 2$ conserva el mayor AUC con dependencia reduciéndose.



Convergencia del entrenamiento

Ambos modelos convergen sin sobreajuste visible. El modelo FAIR es más compacto en épocas gracias al early stopping.



TALLER B4-T1

Auditoría de Incertidumbre y Equidad

Diseño de Redes Confiables · Home Credit Default Risk

Junio 2025

Pilar 4 · Estimador de Incertidumbre

¿Qué hace este modelo?


- No predice si el cliente paga.
- Predice la magnitud del error del modelo principal.
- Target: error absoluto $|y_{\text{true}} - y_{\text{pred}}|$.

Decisiones de diseño clave

- Softplus en salida → incertidumbre siempre positiva.
- Concatenación de ambos canales (Custom + Dense) → visión integral del cliente.
- StandardScaler aplicado antes del entrenamiento.


Curva de Convergencia

Curva de Convergencia: Estimador de Incertidumbre (Escala)



El modelo converge en pocas épocas sin sobreajuste.


Auditoría Ciega - Distribución de Incertidumbre



💡 Conclusión

- Los malos pagadores concentran mayor incertidumbre.
- El sistema reconoce que son perfiles más difíciles de clasificar.
- Especialmente donde EXT_SOURCE tiene peor calidad.
- El modelo sabe cuándo dudar.

Trade-off de Equidad · Frontera de Pareto



Resultados en Test

Modelo	AUC	Acc.	Pearson ²
Base ($\lambda=0$)	0.7205	0.9193	0.001359
FAIR ($\lambda=50$)	0.7054	0.9193	0.000004

▼ **Pearson²: 0.001359 → 0.000004**

Reducción de la dependencia sobre género:
99.7%

▼ **AUC: 0.7205 → 0.7054**

Coste marginal en rendimiento: 2.1%

El sistema no solo predice — sabe cuándo dudar y trata a todos los perfiles de forma equitativa.